

Curso Inteligência Artificial: do Zero ao Infinito

Deteccão de Objetos: Modelos R-CNN

Universidade Federal de Mato Grosso

Agenda

- 1 Introdução
- 2 Detecting Single Object
- 3 Detecting Multiples Objects
- 4 R-CNN
 - Region Proposals
- 5 Fast R-CNN
- 6 Faster R-CNN
- 7 Comparing Boxes
 - Overlapping Boxes
- 8 Tensorflow Object Detection API
- 9 Architectures
 - Datasets

Detecção de Objetos

Introdução

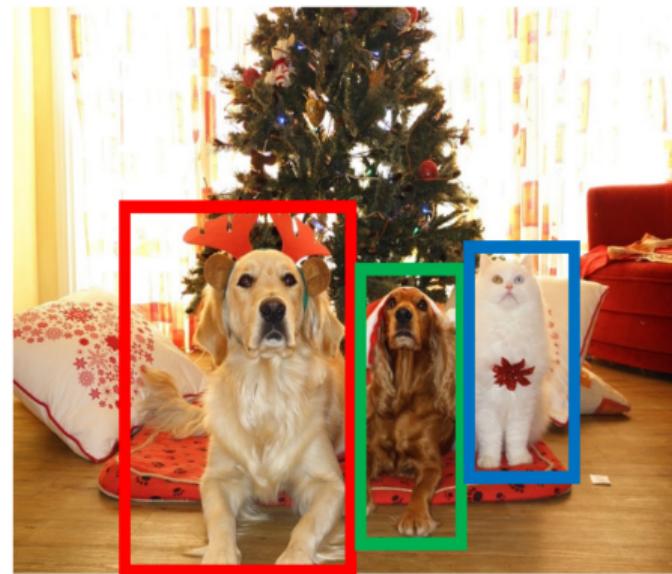
- **Image Classification** é uma tarefa de atribuir uma classe para uma imagem.
- **Object Localization** consiste em localizar um ou mais objetos em uma imagem.
- **Object Detection** combina essas duas tarefas: localizar um ou mais objetos e classificar cada um deles.

Fonte: <https://machinelearningmastery.com/object-recognition-with-deep-learning/>

Detecção de Objetos

Definição da Tarefa

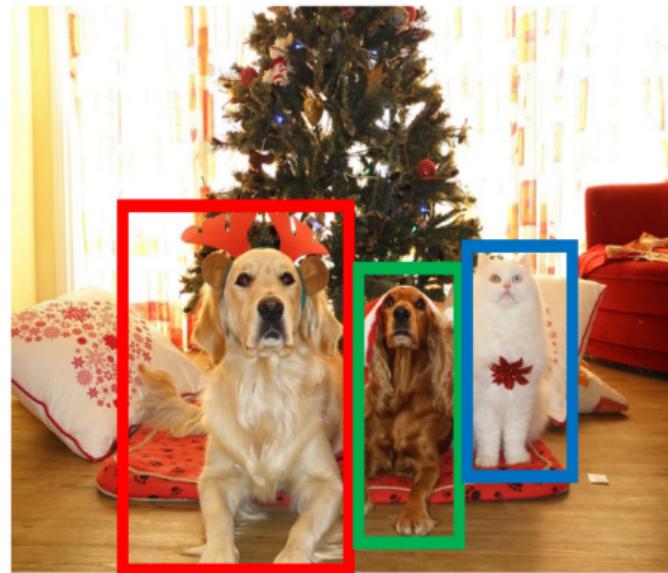
- Entrada: Imagem RGB
- Saída: Um conjunto de objetos detectados; para cada objeto, deve-se ter:
 - ① *Label* (categoria) dentro de um conjunto fixo de categorias.
 - ② *Bounding box* composto por quatro números: x, y, width, height.



Detecção de Objetos

Desafios

- **Múltiplas Saídas:** número variável de objetos detectados por imagem.
- **Múltiplos tipos de saída:** prediz “qual” (label da categoria) e “onde” (*bounding box*).
- **Tamanho** variável de objetos.
- **Dimensão:** classificação funciona em imagens de dimensão 224×224 ; enquanto que detecção deve funcionar em imagens de alta resolução ($\geq 800 \times 600$).



Agenda

- 1 Introdução
- 2 Detecting Single Object
- 3 Detecting Multiples Objects
- 4 R-CNN
 - Region Proposals
- 5 Fast R-CNN
- 6 Faster R-CNN
- 7 Comparing Boxes
 - Overlapping Boxes
- 8 Tensorflow Object Detection API
- 9 Architectures
 - Datasets

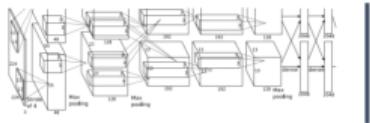
Detecção de Objetos

Detectando um objeto

Detecting a single object



This image is CC0 public domain



Vector:

4096

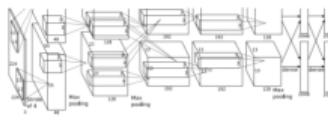
Detecção de Objetos

Detectando um objeto

Detecting a single object



This image is CC0 public domain



Vector:
4096

Fully
Connected:
4096 to 1000

“What”

Class Scores
Cat: 0.9
Dog: 0.05
Car: 0.01
...

Correct label:
Cat
↓
Softmax
Loss

Detecção de Objetos

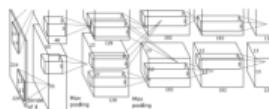
Detectando um objeto

Detecting a single object



This image is CC0 public domain

Treat localization as a regression problem!



“Where”

Vector:
4096

“What”

Fully
Connected:
4096 to 1000

Class Scores

Cat: 0.9
Dog: 0.05
Car: 0.01
...

Fully
Connected:
4096 to 4

Box
Coordinates
(x, y, w, h)

Correct label:

Cat

Softmax
Loss

L2 Loss

Correct box:
(x', y', w', h')

Detecção de Objetos

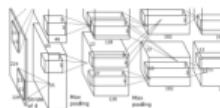
Detectando um objeto



This image is CC0 public domain

Treat localization as a regression problem!

Detecting a single object



“Where”

Fully
Connected:
4096 to 4

Vector:
4096

“What”

Fully
Connected:
4096 to 1000

Class Scores
Cat: 0.9
Dog: 0.05
Car: 0.01
...

Box
Coordinates
(x, y, w, h)

Correct label:

Cat

Softmax
Loss

Weighted
Sum → Loss

L2 Loss

Correct box:
(x', y', w', h')

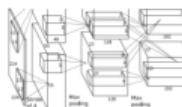
Detecção de Objetos

Detectando um objeto



This image is CC0 public domain

Treat localization as a regression problem!



Detecting a single object

Vector:
4096

Fully
Connected:
4096 to 1000

Fully
Connected:
4096 to 4

“Where”

“What”

Class Scores
Cat: 0.9
Dog: 0.05
Car: 0.01
...

Box
Coordinates
(x, y, w, h)

Correct label:
Cat

Softmax
Loss

Multitask
Loss

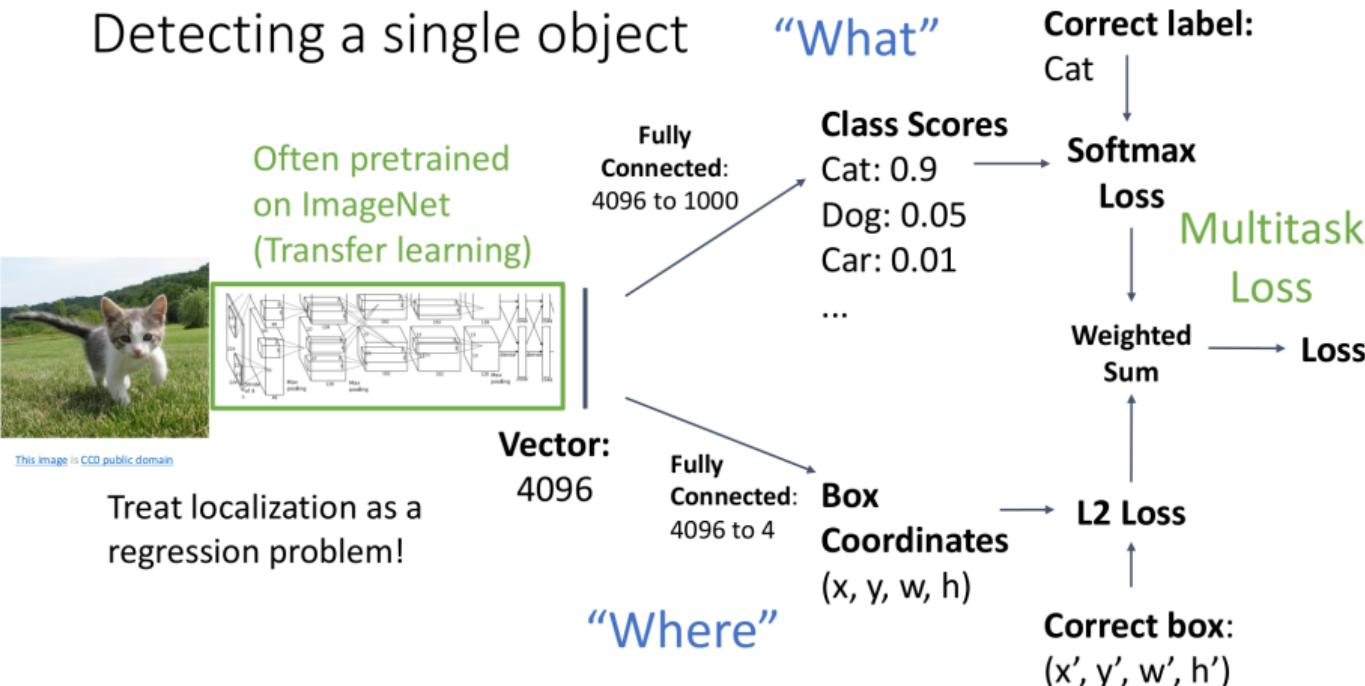
Weighted
Sum

L2 Loss

Correct box:
(x', y', w', h')

Detecção de Objetos

Detectando um objeto



Detecção de Objetos

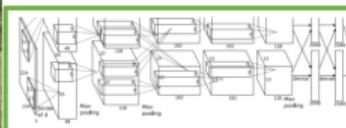
Detectando um objeto

Detecting a single object



This image is CC0 public domain

Often pretrained
on ImageNet
(Transfer learning)



Treat localization as a
regression problem!

Problem: Images can have
more than one object!

Vector:
4096

Fully
Connected:
4096 to 1000

“What”

Class Scores

Cat: 0.9
Dog: 0.05
Car: 0.01
...

Fully
Connected:
4096 to 4

Box
Coordinates
(x, y, w, h)

“Where”

Correct label:

Cat

Softmax

Loss

Multitask
Loss

Weighted
Sum

L2 Loss

Correct box:
(x', y', w', h')

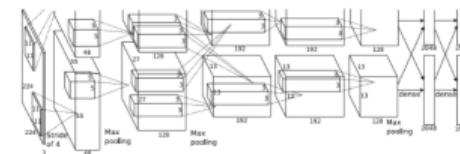
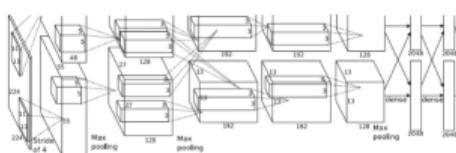
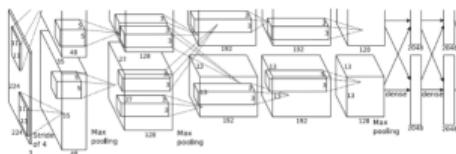
Agenda

- 1 Introdução
- 2 Detecting Single Object
- 3 Detecting Multiples Objects
- 4 R-CNN
 - Region Proposals
- 5 Fast R-CNN
- 6 Faster R-CNN
- 7 Comparing Boxes
 - Overlapping Boxes
- 8 Tensorflow Object Detection API
- 9 Architectures
 - Datasets

Detecção de Objetos

Detectando múltiplos objetos

Detecting Multiple Objects



Need different numbers
of outputs per image

CAT: (x, y, w, h)

4 numbers

DOG: (x, y, w, h)

12 numbers

CAT: (x, y, w, h)

DUCK: (x, y, w, h)

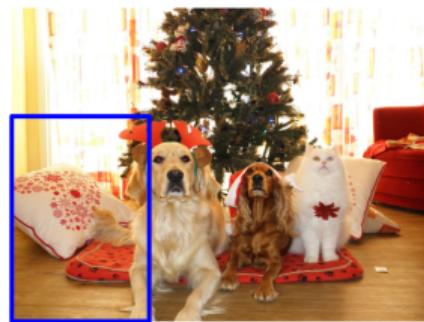
Many
numbers!

Duck image is free to use under the Pixabay license

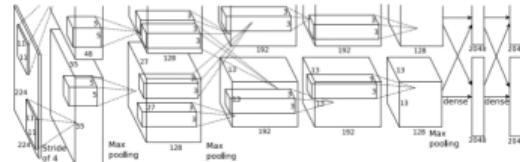
Detecção de Objetos

Detectando múltiplos objetos

Detecting Multiple Objects: Sliding Window



Apply a CNN to many different crops of the image, CNN classifies each crop as object or background



Dog? NO

Cat? NO

Background? YES

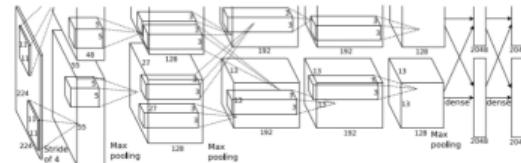
Detecção de Objetos

Detectando múltiplos objetos

Detecting Multiple Objects: Sliding Window



Apply a CNN to many different crops of the image, CNN classifies each crop as object or background



Dog? YES

Cat? NO

Background? NO

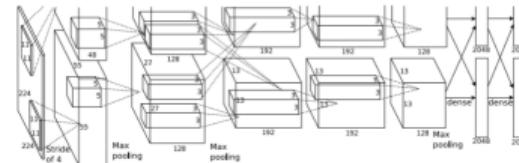
Detecção de Objetos

Detectando múltiplos objetos

Detecting Multiple Objects: Sliding Window



Apply a CNN to many different crops of the image, CNN classifies each crop as object or background



Dog? YES

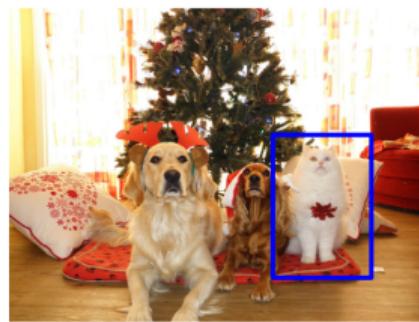
Cat? NO

Background? NO

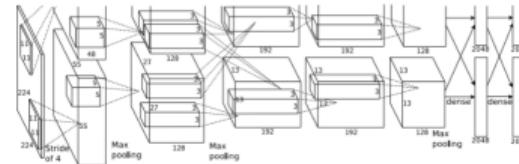
Detecção de Objetos

Detectando múltiplos objetos

Detecting Multiple Objects: Sliding Window



Apply a CNN to many different crops of the image, CNN classifies each crop as object or background



Dog? NO

Cat? YES

Background? NO

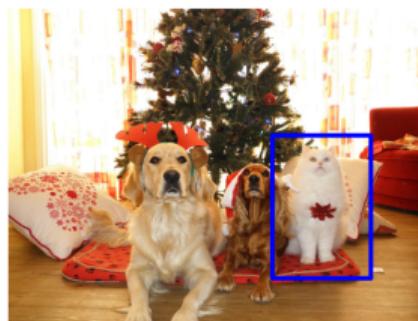
Detecção de Objetos

Detectando múltiplos objetos

Detecting Multiple Objects: Sliding Window

Apply a CNN to many different crops of the image, CNN classifies each crop as object or background

Question: How many possible boxes are there in an image of size $H \times W$?

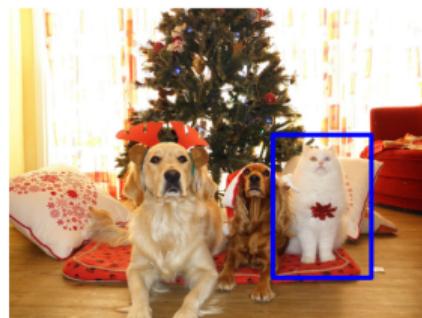


Detecção de Objetos

Detectando múltiplos objetos

Detecting Multiple Objects: Sliding Window

Apply a CNN to many different crops of the image, CNN classifies each crop as object or background



Question: How many possible boxes are there in an image of size $H \times W$?

Consider a box of size $h \times w$:

Possible x positions: $W - w + 1$

Possible y positions: $H - h + 1$

Possible positions:

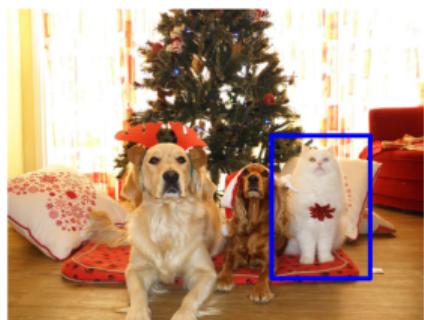
$$(W - w + 1) * (H - h + 1)$$

Detecção de Objetos

Detectando múltiplos objetos

Detecting Multiple Objects: Sliding Window

Apply a CNN to many different crops of the image, CNN classifies each crop as object or background



Question: How many possible boxes are there in an image of size $H \times W$?

Consider a box of size $h \times w$:

Possible x positions: $W - w + 1$

Possible y positions: $H - h + 1$

Possible positions:

$$(W - w + 1) * (H - h + 1)$$

Total possible boxes:

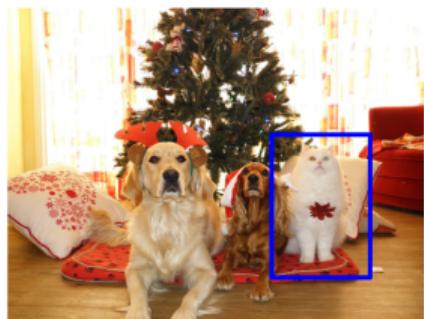
$$\sum_{h=1}^H \sum_{w=1}^W (W - w + 1)(H - h + 1)$$

$$= \frac{H(H + 1)}{2} \frac{W(W + 1)}{2}$$

Detecção de Objetos

Detectando múltiplos objetos

Detecting Multiple Objects: Sliding Window



Apply a CNN to many different crops of the image, CNN classifies each crop as object or background

800 x 600 image
has ~58M boxes!
No way we can evaluate them all

Question: How many possible boxes are there in an image of size $H \times W$?

Consider a box of size $h \times w$:

Possible x positions: $W - w + 1$

Possible y positions: $H - h + 1$

Possible positions:

$$(W - w + 1) * (H - h + 1)$$

Total possible boxes:

$$\sum_{h=1}^H \sum_{w=1}^W (W - w + 1)(H - h + 1)$$

$$= \frac{H(H + 1)}{2} \frac{W(W + 1)}{2}$$

Agenda

- 1 Introdução
- 2 Detecting Single Object
- 3 Detecting Multiples Objects
- 4 R-CNN
 - Region Proposals
- 5 Fast R-CNN
- 6 Faster R-CNN
- 7 Comparing Boxes
 - Overlapping Boxes
- 8 Tensorflow Object Detection API
- 9 Architectures
 - Datasets

R-CNN

- Em 2014, no modelo **R-CNN** foi utilizada uma estratégia para definição das regiões de busca e classificação dessas regiões.
- Essa estratégia consiste em utilizar heurísticas para encontrar *Region Proposals*, que são regiões mais prováveis de conterem um objeto.
- Para seleção das *Region Proposals*, não é definido um método, mas são apresentados diversas propostas.

Paper: Rich feature hierarchies for accurate object detection and semantic segmentation

Sourcecode: Official Github

R-CNN

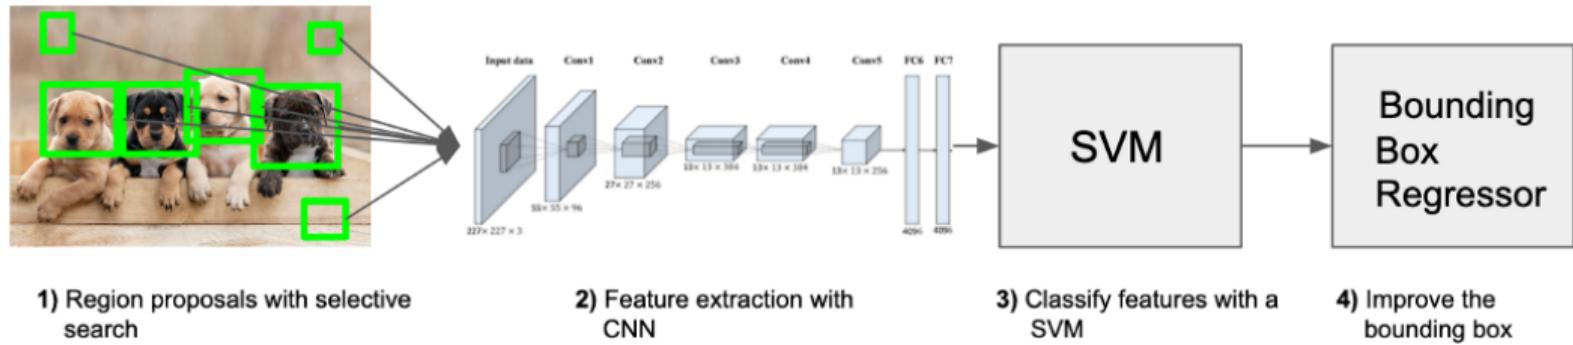
- O método mais utilizado para seleção das *Region Proposals* é denominado *Selective Search*.
- Em cada uma dessas regiões aplica-se uma CNN, a AlexNet, para extração das *features*, treinada no ImageNet.
- Por fim, utiliza-se o SVM como classificador e um regressor neural para prever as *bounding boxes*.

Paper: Rich feature hierarchies for accurate object detection and semantic segmentation

Sourcecode: Official Github

R-CNN

Arquitetura



Fonte: R-CNN (Object Detection)

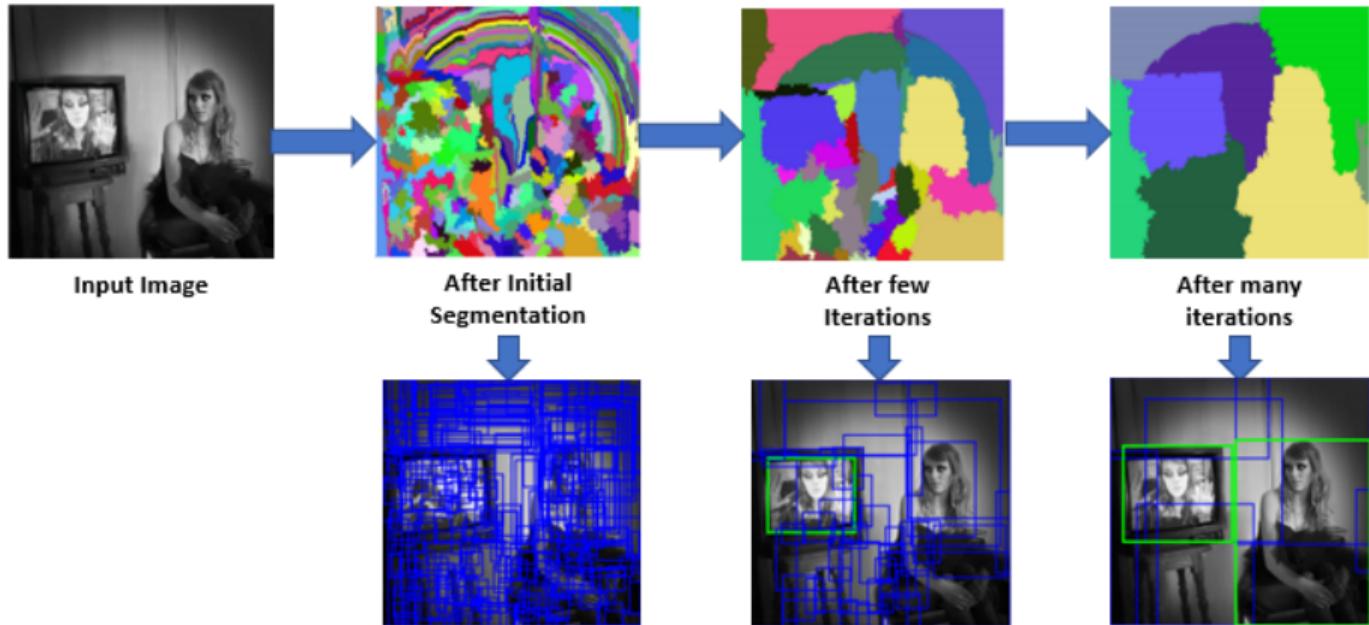
Algoritmo *Selective Search*:

- ① Gere sub-segmentos da imagem de entrada.
- ② Recursivamente combine as regiões similares em regiões maiores.
 - ▶ Dados os conjuntos de regiões, escolha os dois mais similares.
 - ▶ Combine-os em um único conjunto, ou seja, em uma região maior.
 - ▶ Repita os passos anteriores por múltiplas iterações.

Fonte: Selective Search for Object Detection | R-CNN

R-CNN

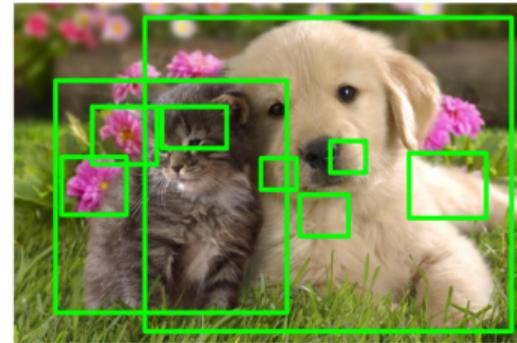
Selective Search



Fonte: Selective Search for Object Detection | R-CNN

Region Proposals

- Defina um pequeno conjunto de *bboxes* que provavelmente cubra todos os objetos.
- Utilize heurísticas para procurar por regiões mais prováveis de conter uma imagem.
- Execução relativamente rápida: *Selective Search* oferece 2k *Region Proposals* em poucos segundos na CPU.



Region Proposals

R-CNN: Region-Based CNN

Input
image



Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014.

Figure copyright Ross Girshick, 2015; [source](#). Reproduced with permission.

Region Proposals

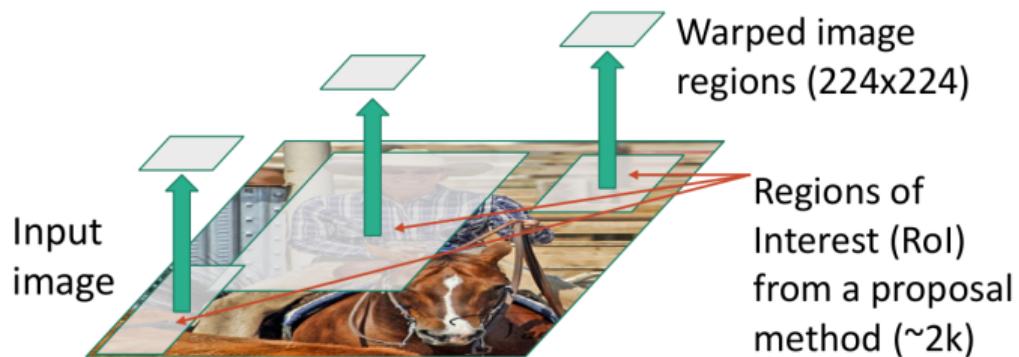
R-CNN: Region-Based CNN



Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014.
Figure copyright Ross Girshick, 2015; [source](#). Reproduced with permission.

Region Proposals

R-CNN: Region-Based CNN

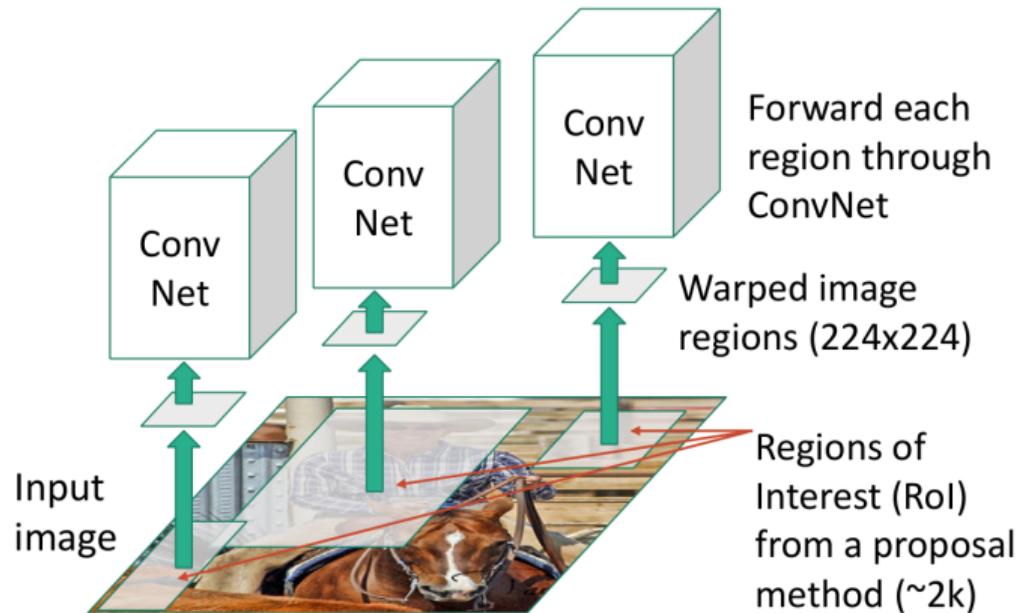


Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014.

Figure copyright Ross Girshick, 2015; [source](#). Reproduced with permission.

Region Proposals

R-CNN: Region-Based CNN



Girshick et al, "Rich feature hierarchies for accurate object detection and semantic segmentation", CVPR 2014.

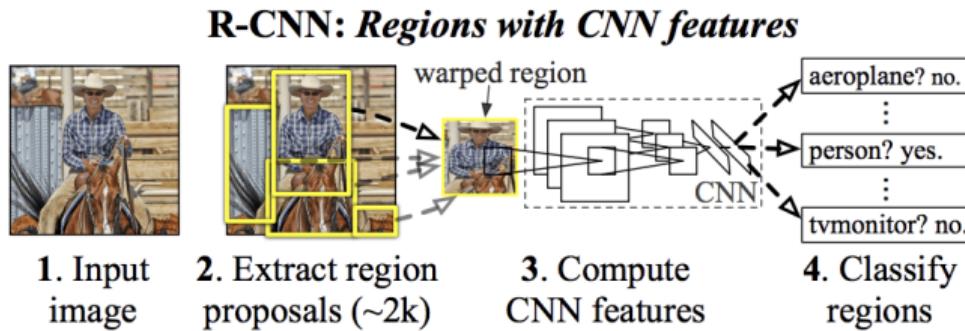
Figure copyright Ross Girshick, 2015; [source](#). Reproduced with permission.

R-CNN

Arquitetura

A arquitetura do R-CNN é composta por três módulos:

- ➊ **Region Proposal.** Gera e extrai as regiões candidatas a *bboxes*.
 - ➋ **Feature Extractor.** Extrai *features* de cada região usando uma rede CNN.
 - ➌ **Classificador.** Classifica cada região um modelo linear de classificação (SVM).



R-CNN

Desvantagens

- Alto custo de treinamento.
 - ▶ Precisa classificar 2000 regiões por imagem.
- Não pode ser implementado em tempo real.
 - ▶ em média, leva 47s para cada imagem de teste.
- O algoritmo *Selective Search* é estático.
 - ▶ Não há aprendizado na geração das *Region Proposals*.
- O treinamento não pode ser paralelizado.
 - ▶ Cada módulo deve ser treinado separadamente.

Fonte: R-CNN, Fast R-CNN, Faster R-CNN, YOLO - Object Detection Algorithms

Agenda

- 1 Introdução
- 2 Detecting Single Object
- 3 Detecting Multiples Objects
- 4 R-CNN
 - Region Proposals
- 5 Fast R-CNN
- 6 Faster R-CNN
- 7 Comparing Boxes
 - Overlapping Boxes
- 8 Tensorflow Object Detection API
- 9 Architectures
 - Datasets

Fast R-CNN

- Em 2015, foi proposta a **Fast R-CNN**, com o intuito de corrigir alguns pontos fracos da *R-CNN*.
- Foram combinados três módulos (CNN, SVM e *bbox regressor*) em um, tornando-o um modelo *end-to-end*.
- Após esse modelo, a R-CNN original ficou conhecida como *Slow R-CNN*.

Paper: Fast R-CNN

Source code: Official Github

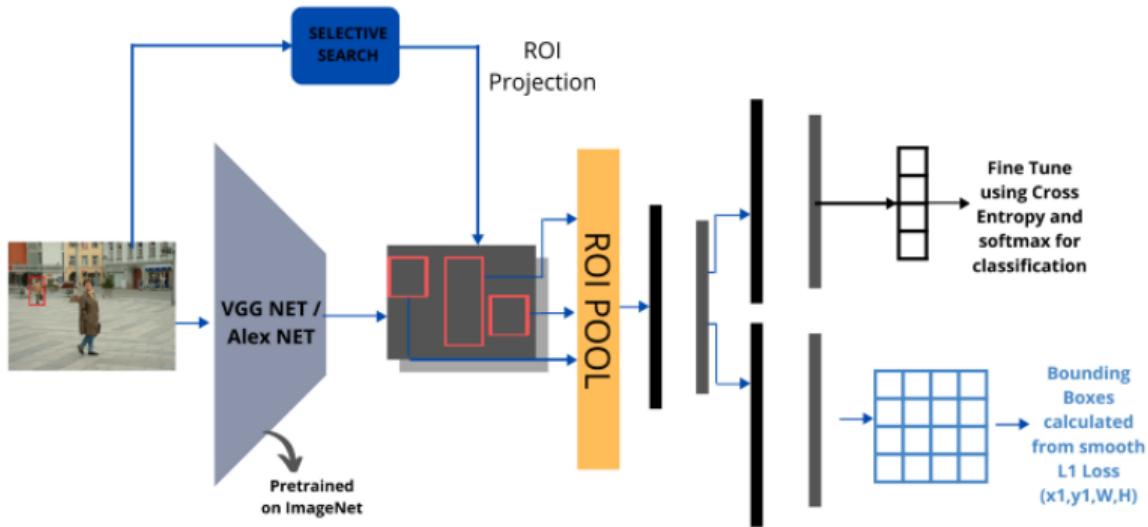
Fast R-CNN

- Nesse modelo, utilizou-se como extrator de *features* o modelo VGG16 pré-treinado na ImageNet.
- Ao invés de se utilizar SVM, optou-se por duas redes FC para predição dos *bboxings* e classificação.
- Isso permitiu um menor tempo de treinamento do modelo e também uma melhor acurácia.

Paper: Fast R-CNN

Source code: Official Github

Fast R-CNN



Fonte: Understanding Fast R-CNN and Faster R-CNN for Object Detection.

Fast R-CNN

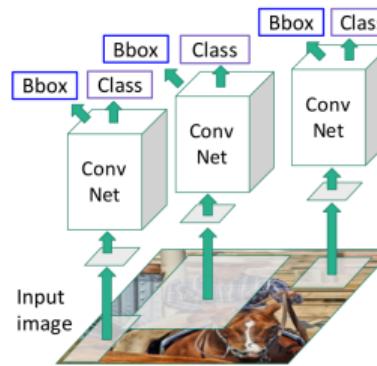
Fast R-CNN



Input image

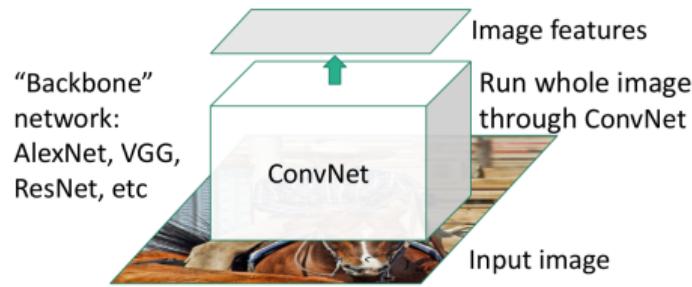
Girshick, "Fast R-CNN", ICCV 2015. Figure copyright Ross Girshick, 2015; [source](#). Reproduced with permission.

"Slow" R-CNN
Process each region
independently



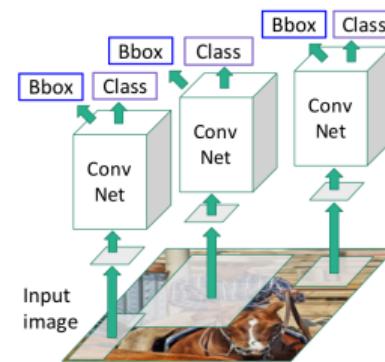
Fast R-CNN

Fast R-CNN



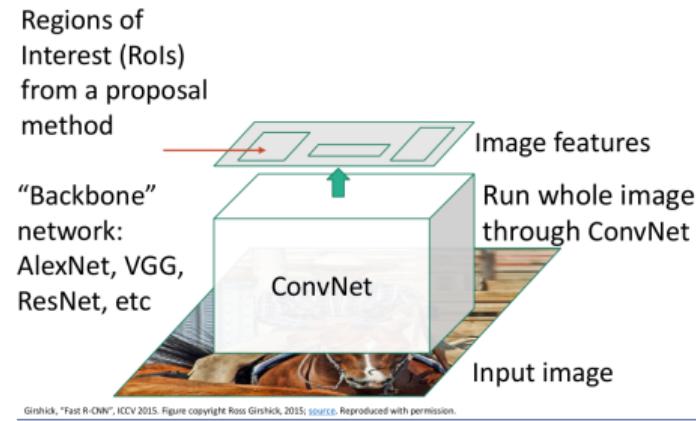
Girshick, "Fast R-CNN", ICCV 2015. Figure copyright Ross Girshick, 2015; [source](#). Reproduced with permission.

"Slow" R-CNN
Process each region
independently

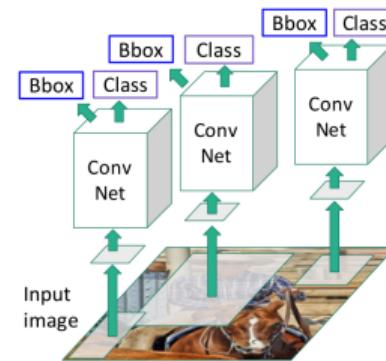


Fast R-CNN

Fast R-CNN



“Slow” R-CNN
Process each region independently



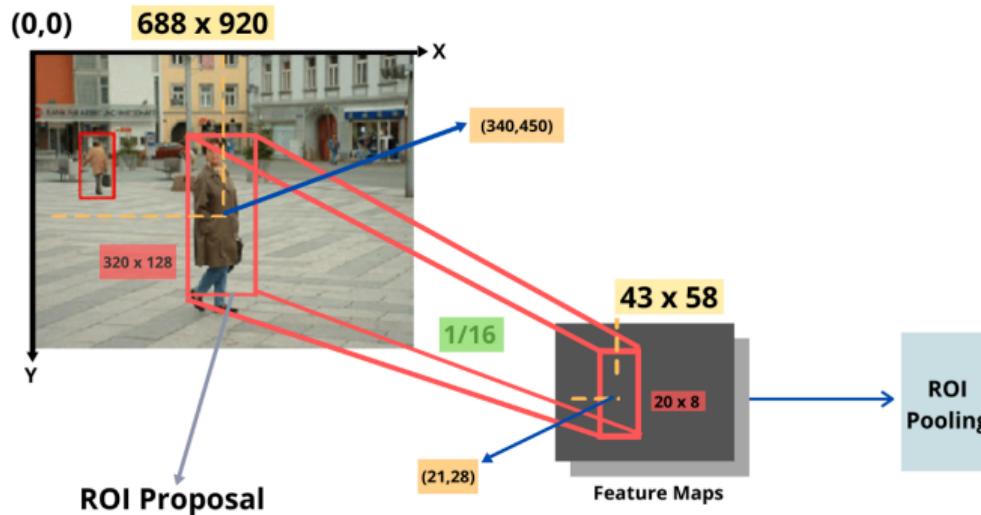
Fast R-CNN

- Na *R-CNN* são geradas 2k *Region Proposals* e cada uma é aplicada à uma CNN extratora de *features*.
 - ▶ Em um dataset com 1k imagens, seriam necessárias 2M (1000×2000) iterações.
- Na **Fast R-CNN** a imagem é enviada para a rede CNN uma única vez, criando um *features map*.
 - ▶ A *Selective Search* é realizada normalmente, definindo 2K *Region Proposals*.
- As *Region Proposals* são projetadas no *features map* gerado pela CNN, num processo denominado **Region of Interest** (ROI).

Fonte: Understanding Fast R-CNN and Faster R-CNN for Object Detection.

Fast R-CNN

As *Region Proposals* são adaptadas num processo de *subsampling ratio* e projetadas no *features map*.

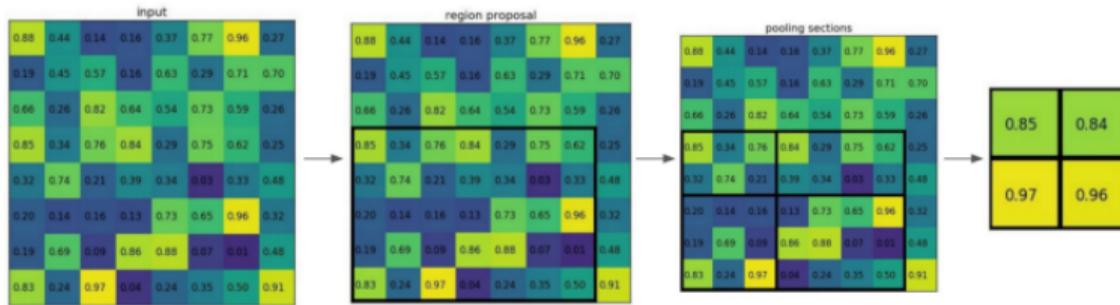


Fonte: Understanding Fast R-CNN and Faster R-CNN for Object Detection.

Fast R-CNN

Region of Interest Pooling

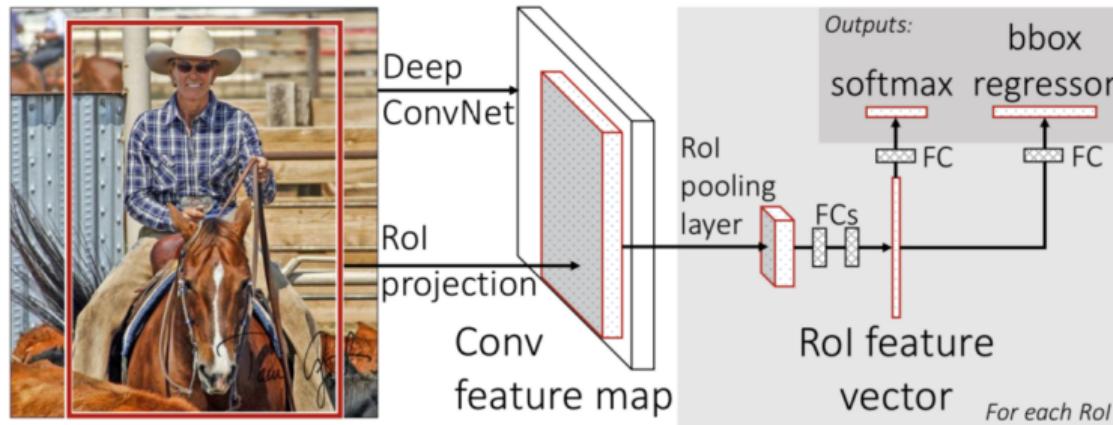
Em seguida, é aplicada uma cada de *pooling layer*, a fim de obter um tamanho fixo, independente da entrada.



A saída de tamanho fixo é importante pois será enviada à uma camada FC.

Fonte: Introduction: Fast R-CNN (Object Detection) e Region of interest pooling explained

Fast R-CNN



Fonte: Fast R-CNN

R-CNN vs Fast R-CNN

	RCNN	Fast RCNN
Training Time	84 hours	9.5 hours
(Speedup)	1x	8.8x
Test time per image	47 seconds	0.32 seconds
(Speedup)	1x	146x
Test time per image with Selective Search	50 seconds	2 seconds
(Speedup)	1x	25x

Fonte: Understanding Fast R-CNN and Faster R-CNN for Object Detection.

Fast R-CNN

- Nos modelos *R-CNN* e *Fast R-CNN* o gargalo do modelo está na definição das *Region Proposals*.
- O algoritmo *Selective Search* demora 2s por imagem e executa em CPU.
- Isso torna esses modelos inviáveis para aplicações em tempo real.

Fonte: R-CNN, Fast R-CNN, Faster R-CNN, YOLO - Object Detection Algorithms

Agenda

- 1 Introdução
- 2 Detecting Single Object
- 3 Detecting Multiples Objects
- 4 R-CNN
 - Region Proposals
- 5 Fast R-CNN
- 6 Faster R-CNN
- 7 Comparing Boxes
 - Overlapping Boxes
- 8 Tensorflow Object Detection API
- 9 Architectures
 - Datasets

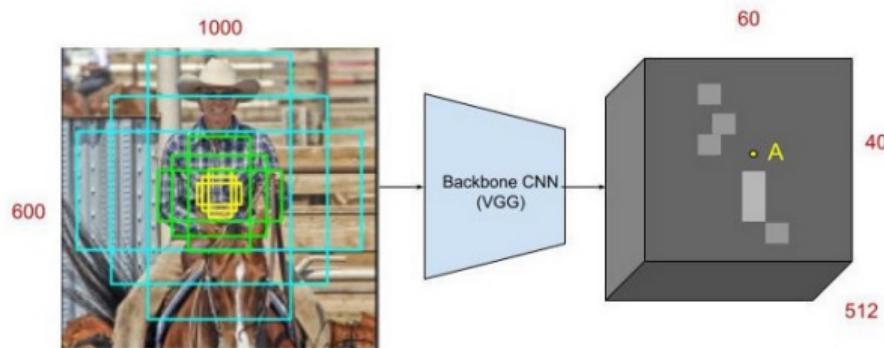
Faster R-CNN

- **Faster R-CNN** eliminou de vez o uso do algoritmo *Selective Search* substituindo-o por uma CNN.
 - ▶ Essa rede CNN é chamada *Region Proposal Network* (RPN).
- O RPN terá as funções de classificador de regressor.
 - ▶ Dessa forma, o tempo para definição das *Region Proposals* cai de 2s para 10ms por imagem.

Paper: Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks

Faster R-CNN

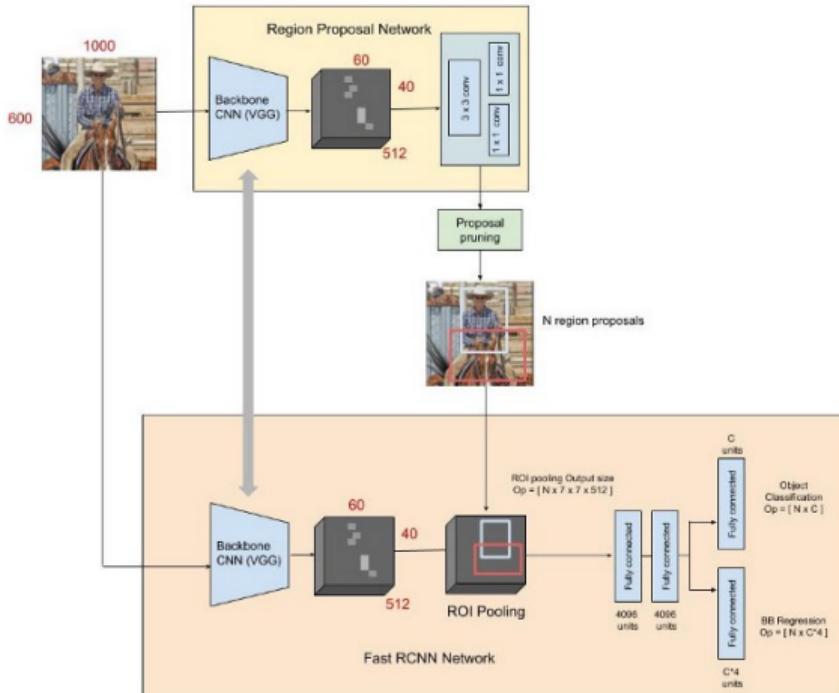
Region Proposal Network



Fonte: Faster R-CNN for object detection

Faster R-CNN

Region Proposal Network



Faster R-CNN

	RCNN	Fast RCNN	Faster RCNN
Test time per image with Proposals	50 seconds	2 seconds	0.2 seconds
(Speedup)	1x	25x	250x
mAP (PASCAL VOC 07)	66.0	66.9	66.9

Fonte: Understanding Fast R-CNN and Faster R-CNN for Object Detection.

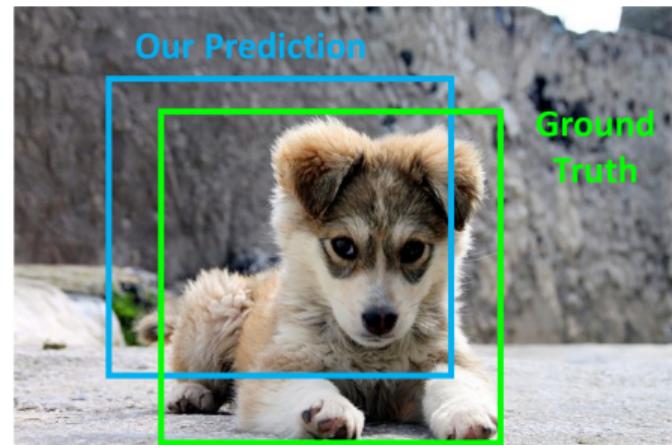
Agenda

- 1 Introdução
- 2 Detecting Single Object
- 3 Detecting Multiples Objects
- 4 R-CNN
 - Region Proposals
- 5 Fast R-CNN
- 6 Faster R-CNN
- 7 Comparing Boxes
 - Overlapping Boxes
- 8 Tensorflow Object Detection API
- 9 Architectures
 - Datasets

Comparing Boxes

Intersection over Union (IoU)

- Como comparar o *box* da predição com o *box* do *ground-truth*?



Puppy image is licensed under CC-A 2.0 Generic license. Bounding boxes and text added by Justin Johnson.

Comparing Boxes

Intersection over Union (IoU)

- Como comparar o *box* da predição com o *box* do *ground-truth*?
- **Intersection over Union (IoU)**: também chamado de “*Similaridade de Jaccard*” ou “*Jaccard index*”.

$$\frac{\text{Area of Intersection}}{\text{Area of Union}}$$



Puppy image is licensed under CC-A 2.0 Generic license. Bounding boxes and text added by Justin Johnson.

Comparing Boxes

Intersection over Union (IoU)

- Como comparar o *box* da predição com o *box* do *ground-truth*?
- **Intersection over Union (IoU)**: também chamado de “*Similaridade de Jaccard*” ou “*Jaccard index*”.

$$\frac{\text{Area of Intersection}}{\text{Area of Union}}$$

- IoU > 0.5 é “aceitável”,



Pups image is licensed under CC-A 2.0 Generic license. Bounding boxes and text added by Justin Johnson.

Comparing Boxes

Intersection over Union (IoU)

- Como comparar o *box* da predição com o *box* do *ground-truth*?
- **Intersection over Union (IoU)**: também chamado de “*Similaridade de Jaccard*” ou “*Jaccard index*”.

$$\frac{\text{Area of Intersection}}{\text{Area of Union}}$$

- $\text{IoU} > 0.5$ é “aceitável”,
- $\text{IoU} > 0.7$ é “*muito bom*”,



Puppy image is licensed under CC-A 2.0 Generic license. Bounding boxes and text added by Justin Johnson.

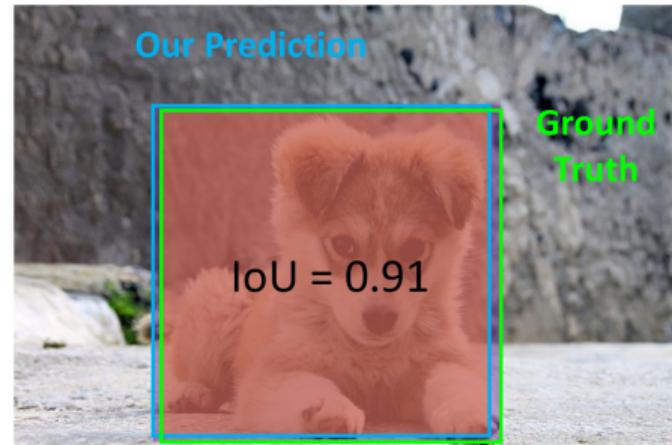
Comparing Boxes

Intersection over Union (IoU)

- Como comparar o *box* da predição com o *box* do *ground-truth*?
- **Intersection over Union (IoU)**: também chamado de “*Similaridade de Jaccard*” ou “*Jaccard index*”.

$$\frac{\text{Area of Intersection}}{\text{Area of Union}}$$

- $\text{IoU} > 0.5$ é “aceitável”,
- $\text{IoU} > 0.7$ é “muito bom”,
- $\text{IoU} > 0.9$ é “quase perfeito”.

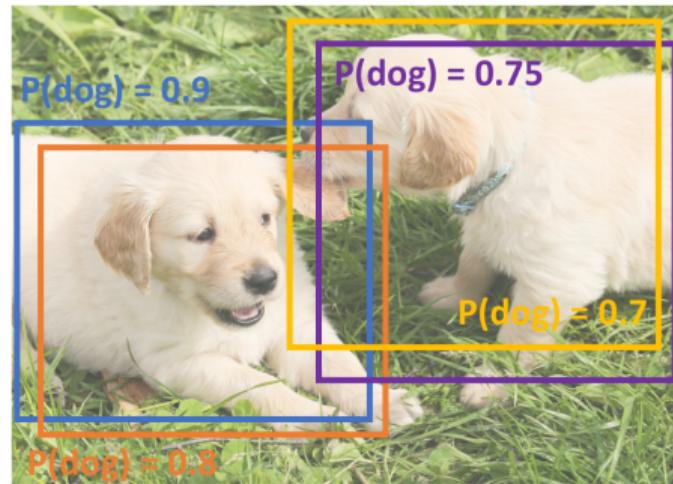


Puppy image is licensed under CC-A 2.0 Generic license. Bounding boxes and text added by Justin Johnson.

Comparing Boxes

Overlapping Boxes

- **Problema:** *Object Detectors* frequentemente detectam *boxes* sobrepostos:

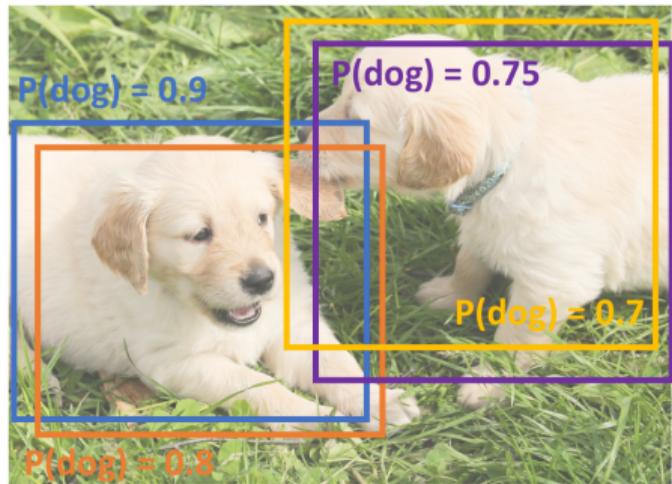


Puppy image is CC0 Public Domain

Comparing Boxes

Overlapping Boxes: Non-Max Suppression (NMS)

- **Problema:** *Object Detectors* frequentemente detectam *boxes* sobrepostos:
- **Solução:** pós-processar detecções utilizando **Non-Max Suppression (NMS)**
 - 1 Seleione o *box* com maior *score*.
 - 2 Elimine *boxes* com baixo *score*.
 - ★ $\text{IoU} > \text{threshold}$ (ex. 0.7).
 - 3 Se restarem *boxes*, GOTO 1.



Puppy image is CC0 Public Domain

Comparing Boxes

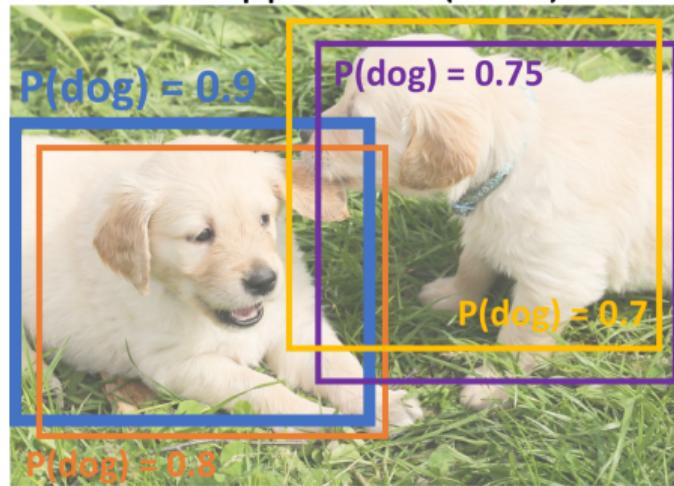
Overlapping Boxes: Non-Max Suppression (NMS)

- **Problema:** *Object Detectors* frequentemente detectam *boxes* sobrepostos:
- **Solução:** pós-processar detecções utilizando **Non-Max Suppression (NMS)**
 - 1 Seleione o *box* com maior *score*.
 - 2 Elimine *boxes* com baixo *score*.
 - ★ $\text{IoU} > \text{threshold}$ (ex. 0.7).
 - 3 Se restarem *boxes*, GOTO 1.

$$\text{IoU}(\text{blue}, \text{orange}) = 0.78$$

$$\text{IoU}(\text{blue}, \text{purple}) = 0.05$$

$$\text{IoU}(\text{blue}, \text{yellow}) = 0.07$$

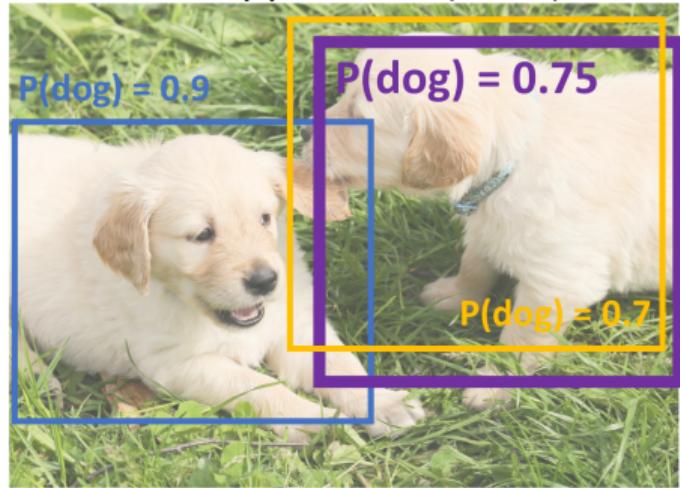


Puppy image is CC0 Public Domain

Comparing Boxes

Overlapping Boxes: Non-Max Suppression (NMS)

- **Problema:** *Object Detectors* frequentemente detectam *boxes* sobrepostos:
- **Solução:** pós-processar detecções utilizando **Non-Max Suppression (NMS)**
 - 1 Seleione o *box* com maior *score*.
 - 2 Elimine *boxes* com baixo *score*.
 - ★ $\text{IoU} > \text{threshold}$ (ex. 0.7).
 - 3 Se restarem *boxes*, GOTO 1.
 $\text{IoU}(\text{purple}, \text{yellow}) = 0.74$

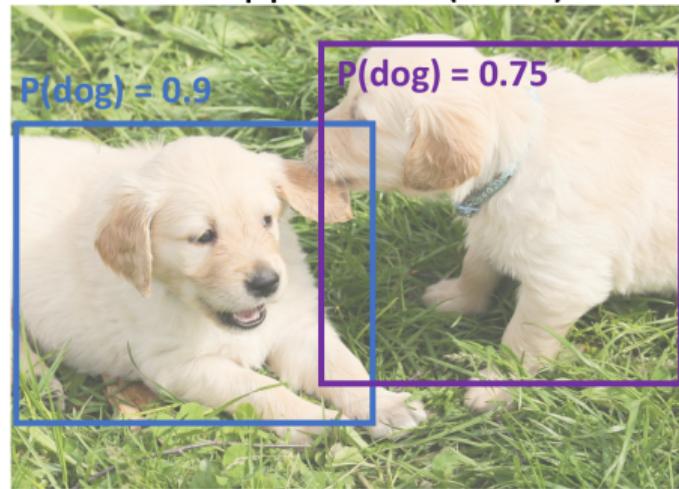


Puppy image is CC0 Public Domain

Comparing Boxes

Overlapping Boxes: Non-Max Suppression (NMS)

- **Problema:** *Object Detectors* frequentemente detectam *boxes* sobrepostos:
- **Solução:** pós-processar detecções utilizando **Non-Max Suppression (NMS)**
 - 1 Seleccione o *box* com maior *score*.
 - 2 Elimine *boxes* com baixo *score*.
 - ★ $\text{IoU} > \text{threshold}$ (ex. 0.7).
 - 3 Se restarem *boxes*, GOTO 1.



Puppy image is CC0 Public Domain

Comparing Boxes

Overlapping Boxes: Non-Max Suppression (NMS)

- **Problema:** *Object Detectors* frequentemente detectam *boxes* sobrepostos:
- **Solução:** pós-processar detecções utilizando **Non-Max Suppression (NMS)**
 - ① Selecione o *box* com maior *score*.
 - ② Elimine *boxes* com baixo *score*.
 - ★ $\text{IoU} > \text{threshold}$ (ex. 0.7).
 - ③ Se restarem *boxes*, GOTO 1.
- **Problema:** NMS pode eliminar *boxes* “bons” quando os objetos estão sob muita sobreposição... nesse caso não existe solução boa.



Crowd image is free for commercial use under the Pixabay license

Agenda

- 1 Introdução
- 2 Detecting Single Object
- 3 Detecting Multiples Objects
- 4 R-CNN
 - Region Proposals
- 5 Fast R-CNN
- 6 Faster R-CNN
- 7 Comparing Boxes
 - Overlapping Boxes
- 8 Tensorflow Object Detection API
- 9 Architectures
 - Datasets

Tensorflow Object Detection API

Tutorial

- Para utilizar os modelos descritos é possível utilizar a API de **Object Detection** do [Tensorflow](#).
- É um *framework Open Source* baseado em Tensorflow.
- Fornece suporte para criação de modelos capazes de localizar e identificar objetos em uma imagem.

Tensorflow Object Detection API

Tutorial

Vamos aprender:

- Preparação do ambiente utilizando Google Colab.
- Ferramentas para criação de datasets.
- Organização dos dados de treinamento.
- Configurar o treinamento.
- Treinar e salvar o modelo.

Tensorflow Object Detection API

Tutorial

Existem outras ferramentas e é possível encontrar algumas outras através do link:

- https://en.wikipedia.org/wiki/List_of_manual_image_annotation_tools

Encontre a que mais goste...

Agenda

- 1 Introdução
- 2 Detecting Single Object
- 3 Detecting Multiples Objects
- 4 R-CNN
 - Region Proposals
- 5 Fast R-CNN
- 6 Faster R-CNN
- 7 Comparing Boxes
 - Overlapping Boxes
- 8 Tensorflow Object Detection API
- 9 Architectures
 - Datasets

Detecção de Objetos

Arquiteturas

- **R-CNN** (Regions with Convolutional Network)
- **Fast-RCNN**
- **Faster-RCNN**
- **SSD** (Single Shot Detection)
- **YOLO** (You Only Look Once)
- **R-FCNN** (Region-Based Convolutional Network)
- **SqueezeDet**
- Dentre outras...

Fonte: <https://machinelearningmastery.com/convolutional-layers-for-deep-learning-neural-networks/>

Detecção de Objetos

Datasets

Os principais datasets utilizados para Detecção de objetos são:

- **Open Images v4:** 9M imagens com 600 classes
 - ▶ Download: <https://storage.googleapis.com/openimages/web/index.html>
- **ImageNet:** 450k imagens com 200 classes
 - ▶ <https://image-net.org/challenges/LSVRC/>
- **COCO:** 120k imagens com 80 classes
 - ▶ Download: <https://cocodataset.org/>
- **Pascal VOC:** 12k imagens com 20 classes
 - ▶ <http://host.robots.ox.ac.uk/pascal/VOC/>
- **Oxford-IIIT Pet:** 7k imagens com 37 classes
 - ▶ <https://www.robots.ox.ac.uk/~vgg/data/pets/>
- **KITTI Vision:** 7k imagens com 3 classes
 - ▶ <http://www.cvlibs.net/datasets/kitti/>

Referências

- Deep Learning for Computer Vision - University of Michigan
 - ▶ Lecture 15: Object Detection
- Object Detection for Dummies
 - ▶ Object Detection for Dummies Part 1: Gradient Vector, HOG, and SS
 - ▶ Object Detection for Dummies Part 2: CNN, DPM and Overfeat
 - ▶ Object Detection for Dummies Part 3: R-CNN Family
 - ▶ Object Detection for Dummies Part 4: Fast Detection Models

Curso Inteligência Artificial: do Zero ao Infinito

Deteccão de Objetos: Modelos R-CNN

Universidade Federal de Mato Grosso